КАРТОЧКА МЕТОДОЛОГИИ ИССЛЕДОВАНИЯ

Methodology Passport Card | Course: Research Methods | Task 2

1. Информация о проекте (Project Information)

Название работы:	Влияние конфигурации извлечения (top-k и размер фрагмента) на уровень галлюцинаций в вопросно-ответных системах с генерацией на основе поиска (RAG)
English Title:	Effect of Retrieval Configuration (top-k and chunk size) on the Hallucination Rate of Retrieval-Augmented Question Answering with an Open-Weight LLM
Автор / Пара:	Айбар Алауов (Aibar Alauov) — aibar.alauov@narxoz.com
GitHub Репозиторий:	https://github.com/alauovaibar/researchMethods

2. Тип исследования (Research Type)

Тип: Количественное экспериментальное исследование (Quantitative Empirical Benchmark Study).

Обоснование выбора: Исследование направлено на выявление эмпирических причинно-следственных зависимостей и многофакторную оптимизацию гиперпараметров извлечения информации (top-k, chunk_size, позиция контекста) на объективно измеримые количественные метрики качества ответов LLM (Hallucination Rate, Faithfulness, Token F1, задержка инференса). Проверка гипотез выполняется с использованием дисперсионного анализа (ANOVA) и post-hoc теста Тьюки (α = 0.05).

3. Формулировка гипотез (Hypotheses Formulation)

Нулевая гипотеза (H0): Средний уровень галлюцинаций (Hallucination Rate) генерируемых ответов не зависит от параметров извлечения top-k (1, 3, 5, 10, 20) и размера чанка (128, 256, 512, 1024 токенов): $\mu_1 = \mu_3 = \mu_5 = \mu_{10} = \mu_{20}$ ($\alpha = 0.05$).

Альтернативная гипотеза (H1): Существует статистически значимая U-образная зависимость между глубиной извлечения и уровнем галлюцинаций: при малых k (k=1) уровень галлюцинаций повышен из-за нехватки доказательств; в диапазоне $k \in [3, 5]$ достигается минимум галлюцинаций; при $k \geq 10$ уровень галлюцинаций возрастает вследствие отвлекающего шума пассажей (distractor noise) и рассеивания внимания декодера.

4. Матрица переменных (Variables Matrix)

Категория	Переменная	Тип / Значения	Роль в эксперименте
Независимая (IV1)	top_k	1, 3, 5, 10, 20	Глубина извлечения пассажей из векторного индекса
Независимая (IV2)	chunk_size	128, 256, 512, 1024	Гранулярность разбиения документов корпуса
Независимая (IV3)	gold_position	first, middle, last, auto	Позиция эталона для проверки 'Lost in the Middle'
Зависимая (DV1)	Hallucination Rate	0.0 - 1.0 (доля)	Первичная метрика: доля неподтвержденных фактов
Зависимая (DV2)	Faithfulness Score	0.0 - 1.0 (RAGAs)	Фактическая верность сгенерированного ответа контексту
Зависимая (DV3)	Token F1 / EM	0.0 - 1.0	Согласованность с эталонным экспертным ответом
Зависимая (DV4)	Latency (мс)	> 0 мс	Суммарное время поиска и генерации
Контролируемая (CV1)	LLM Модель	Llama-3-8B-Instruct	Фиксированная открытая генеративная модель
Контролируемая (CV2)	Параметры декодирования	temp=0.0, seed=42	Строгая детерминированная жадная генерация
Контролируемая (CV3)	Модель эмбеддингов	Dense Cosine (dim=384)	Единое координатное пространство сходства
Контролируемая (CV4)	Промпт-шаблон	Strict Factual RAG	Единый системный промпт без изменения формулировок

5. Выбранные метрики и Baseline (Metrics & Baseline)

Первичная метрика (Primary Metric): Hallucination Rate (доля неподтвержденных утверждений в ответе) и Faithfulness Score = 1.0 - HR. Значение 0.0 означает 100% обоснованность текста.

Пороговые метрики (Guardrail Metrics): P95 Latency ≤ 2500 мс; Контекст ≤ 8192 токенов; Error Rate = 0.0%; RAM ≤ 4096 МБ.

Контрольная группа / Baseline: Baseline 0 (No-RAG, k=0) — генерация без контекста (базовая склонность к галлюцинациям); Baseline 1 (Standard Vanilla RAG) — индустриальный стандарт по умолчанию: top_k=3, chunk_size=256, auto positioning.